

Tema 2 : Distribuciones unidimensionales

- Distribución de frecuencias :

X	n
x_1	n_1
x_2	n_2
\vdots	\vdots
	$\sum n_i = n$

Recorrido de una variable = range values

$$= \max x_i - \min x_i$$

- Frecuencia relativa = $f_i = n_i/n$ ($n = \sum n_i$)

Frecuencia absoluta acumulada = $N_i = n_1 + \dots + n_i$


Frecuencia relativa acumulada = $F_i = \frac{N_i}{n} = f_1 + \dots + f_i$

2.3 - Representación gráfica

(1) Diagrama de barras

(2) Histograma (área = frecuencia)

(3) Polígono de frecuencia



↳ Ojiva: cuando utilizamos freq. acumuladas

(4) Diagrama de tallo y hoja

0	2
1	4 5
2	5 8
3	9 6 8
4	7 3 4

Tema 3: Características de la distribución de frecuencias

Medidas → Posición (media, mediana, moda)

Medidas → Dispersion (grado de concentración)

Medidas → Forma (ej. curtosis, informan sobre aspecto gráfico).

3.1 - Medidas de posición

- Media aritmética $\bar{x} = \frac{\sum x_i n_i}{n}$
- Mediana M_e
- Moda (si es por intervalos, la medida del intervalo más común = frecuencia/longitud del inter) M_o
- Media geométrica $G = \sqrt[n]{\prod x_i^{n_i}}$
- Media armónica $H = \frac{n}{\sum \frac{1}{x_i n_i}}$

Quantiles: valores de la variable que dividen la distribución de frecuencias en cierto número de partes iguales.

3.2 - Medidas de dispersión

- Recorrido $R = \max x_i - \min x_i$
- Recorrido intercuartilico $= Q_3 - Q_1$ (3er y 1er cuartil)
- Desviación mediana $D_{ME} = \frac{\sum |x_i - M_e| n_i}{n}$
- Varianza $s^2 = \frac{\sum (x_i - \bar{x})^2 n_i}{n}$ ($= E[(x - \mu)^2]$)
- Desviación típica $s = \sqrt{s^2} = \sigma$
 - Teorema de Chebyshov: $P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$.
- Coefficiente de asimetría: $C_A = \frac{\max x_i - \min x_i}{R}$
- Recorrido semi-intercuartilico: $R_{SI} = \frac{Q_3 - Q_1}{Q_3 + Q_1}$
- Variación mediana: $V_{ME} = D_{ME}/M_e$
- Coefficiente de variación de Pearson: $C_V = \frac{s}{\bar{x}} \cdot 100$

3.3 - Medidas de forma


- Coefficiente de asimetría de Pearson

$$A_p = \frac{3(\bar{x} - M_e)(\bar{x} - M_o)}{s^3}$$

* $A_p = 0$: simétrica

* $A_p > 0$: asimétrica tte (derecha)

* $A_p < 0$: asimétrica -ve (izquierda)



- Coefficiente de asimetría de Fisher

$$g_1 = \frac{m_3}{s^3} = \frac{\frac{1}{n} \sum (x_i - \bar{x})^3 n_i}{[\sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2 n_i}]} = \frac{E[(x - \bar{x})^3]}{E[(x - \bar{x})^2]^{3/2}}$$

* $g_1 = 0$: simétrica

* $g_1 > 0$: asimétrica tte

* $g_1 < 0$: asimétrica -ve

- La curtosis se refiere a la mayor o menor concentración de valores alrededor de la zona central de la distribución.

$$g_2 = \frac{m_4}{s^4} - 3 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^4 n_i}{(\sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2 n_i})^2} - 3.$$

$g_2 = 0$

$g_2 > 0$

$g_2 < 0$

mesocúrtica

leptocúrtica

platicúrtica

- 3.4 Cambios de origen y escala:

$$x_i^* = a + x_i$$

$$x_i^* = b x_i$$

- Tipificación: operación $t_i = \frac{x_i - \bar{x}}{s}$.

- Escala derivada: supongamos que un profesor quiere que las notas de un examen tengan una media de 5,5 y desviación de 1,2. Deberá encontrar x_i y luego tener $x_i^* = 5,5 + 1,2 x_i$.

Apéndice:

- Momentos respecto a la media $\rightarrow m_1 = 0$


$$m_r = \frac{1}{n} \sum_i (x_i - \bar{x})^r n_i$$

$$m_2 = s^2$$

Tema 4 - Medidas de concentración:

- Grado de concentración: ej: cómo se reparte la renta de un país.
 - * concentración máx: $x_1 = \dots = x_{n-1} = 0$, $x_n = X$
 - * concentración mín: $x_i = x_{n-i}$.

4.1 Curva de Lorentz:



$$P_i = \frac{n_1 + \dots + n_i}{n} \times 100$$

$$Q_i = \frac{x_{1,n} + \dots + x_{i,n}}{n} \times 100$$

(ie. Q_i es cuanta renta tiene en total una fracción P_i de la población).

4.2 - Índice de Gini

$$= \frac{\text{Área sombreada}}{\text{Área del triángulo}} = \frac{\sum (P_i - Q_i)}{\sum P_i} = f_G$$

* $f_G = 0$: igualitario

* $f_G = 1$: muy desigual.

Tema 5 - Distribuciones bidimensionales

5.5 Medidas de dispersión y posición

$$* \bar{x} = \frac{1}{n} \sum_{i,j} x_i n_{ij}, \quad \bar{y} = \frac{1}{n} \sum_{i,j} y_j n_{ij}$$

$$S_x^2 = \frac{1}{n} \sum_{i,j} (x_i - \bar{x})^2 n_{ij}, \quad S_y^2 = \frac{1}{n} \sum_{i,j} (y_j - \bar{y})^2 n_{ij}$$

$$S_{xy} = \frac{1}{n} \sum_{i,j} (x_i - \bar{x})(y_j - \bar{y}) n_{ij}$$

↑ covarianza.

$$* C-S nos da \quad -S_x S_y \leq S_{xy} \leq S_x S_y .$$

5.6 Independencia

$$* \text{Independencia si } \frac{n_{ij}}{n} = \frac{n_{ix}}{n} \times \frac{n_{j*}}{n}$$

$$\Leftrightarrow f_{ij} = f_{ix} \times f_{j*} .$$

$$\text{La independencia} \Rightarrow S_{xy} = 0 .$$

Tema 6 - Regresión y correlación simple

6.1 Covariación

* Coeficiente de correlación lineal : $r = \frac{S_{xy}}{S_x S_y}$
 $-1 \leq r \leq 1$ por C-S.

* Regresión : intentamos determinar una función f tal que $y = f(x)$.

6.2 Regresión Lineal Simple (RLS)

* y_i^* : $y_i^* = a + b x_i \rightarrow e_i = y_i - y_i^*$
 y observado y ajustada residuo
 $\therefore y_i = y_i^* + e_i = a + b x_i + e_i$

* Para ajustar intentamos minimizar $\sum_{i=1}^n e_i^2$.

$$\Leftrightarrow \min_{a,b} \sum_{i=1}^n (y_i - a - b x_i)^2$$

$$\frac{\partial}{\partial a} : -2 \sum_{i=1}^n (y_i - a - b x_i) = 0$$

$$\frac{\partial}{\partial b} : -2 \sum_{i=1}^n (y_i - a - b x_i) x_i = 0$$

\Leftrightarrow se deducen las ecuaciones normales

$$\sum y_i = n a + b \sum x_i \quad ①$$

$$\sum y_i x_i = a \sum x_i + b \sum x_i^2$$

Por lo tanto deducimos

$$b = \frac{S_{xy}}{S_x^2}, a = \bar{y} - b \bar{x} \quad ②$$

6.3 Medidas de bondad de ajuste

• Varianza residual $s_e^2 := \frac{\sum e_i^2}{n} \leftarrow$ si es alta, mal ajustado

$$s_p^2 = \frac{s_{y^*}^2 + s_e^2}{n} \leftarrow = \frac{1}{n} \sum (y_i - y_i^*)^2$$

var. total var. explicada var. residual

$$\frac{1}{n} \sum (y_i^* - \bar{y})^2$$

• Coeficiente de determinación : $R^2 = \frac{s_{y^*}^2}{s_y^2} \leftarrow \text{alto} = \text{bien}$

$$= S_{xy}^2 / S_x^2 S_y^2$$

6.3 Ajuste de funciones no lineales

* $y = a x^b$ (utilizar $\ln y = \ln a + b \ln x$ y luego resolver como si fueran RLS).

* Exponentiales $y = a b^{x_i}$, $e^{y_i} = a x_i^b$.

* Hiperbólicas, $y = a + \frac{b}{x_i}$ (utilizar $z = \frac{1}{x}$).

Tema 7 - Regresión múltiple

7.1 - Regresión lineal múltiple

$$\circ Y = b_1 + b_2 X_2 + \dots + b_K X_K$$

$$\hookrightarrow Y_i = b_1 + b_2 X_{2i} + \dots + b_K X_{Ki}$$

$$\therefore Y = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = Xb + e = \begin{pmatrix} 1 & x_{21} & \dots & x_{K1} \\ \vdots & \vdots & & \vdots \\ 1 & x_{2n} & \dots & x_{Kn} \end{pmatrix} \begin{pmatrix} b_1 \\ \vdots \\ b_K \end{pmatrix} + \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix}$$

Las ecuaciones normales nos dan

$$\boxed{b = (X^T X)^{-1} X^T Y}$$

$$\bullet \text{Varianza residual} = s_e^2 = \frac{\|e\|^2}{n} = \frac{\|Y - bX\|^2}{n} = \dots = \frac{\|Y\|^2 - b^T X^T Y}{n}$$


$$\bullet \text{Coeficiente de determinación múltiple} : R^2 = 1 - \frac{s_e^2}{S_y^2} \text{ donde}$$

$$S_y^2 = \frac{\|Y\|^2 - n \bar{Y}^2}{n}$$

7.2 Regresión lineal con variables ficticias

- A veces es útil añadir un 'fixed effect': añadimos una variable discreta (por ejemplo $D = \begin{cases} 0 & \text{varón} \\ 1 & \text{mujer} \end{cases}$) en una regresión para averiguar el sueldo en una empresa). Son los famosos dummy variables. Simplemente ajustamos el intercepto: creamos K rectas una para cada valor de D . \uparrow sueldo

~~Punto de~~



Tema 8 - Estadística de atributos

- A veces tenemos que estudiar atributos nominales (las modalidades no admiten ordenación, ej.: colores).
- Si tenemos dos atributos podemos hacer una tabla de contingencia:

Ai \ Bj	B1	B2	..	Bn	↓
A1	n ₁₁	n ₁₂	..	n _{1n}	
A2	n ₂₁	n ₂₂	..	n _{2n}	
⋮	⋮	⋮	⋮	⋮	⋮
An	n _{n1}	- - -		n _{nn}	

Si queremos demostrar la independencia de los atributos, necesitamos

$$\frac{n_{ij}}{n} = \frac{n_{i*}}{n} \times \frac{n_{*j}}{n}$$

- Cuando los atributos no son independientes podemos analizar el grado de relación.

* Coeficiente de contingencia:

Si $n_{ij}^* = \frac{n_{ij} \times n_{*j}}{n^2}$ son las frecuencias teóricas

$= \frac{n_{i*} \times n_{*j}}{n}$. Entonces,

$$\chi^2 = \sum_{i,j} \frac{(n_{ij}^* - n_{ij})^2}{n_{ij}^*} \quad \leftarrow \begin{array}{l} 0 = \text{independ.} \\ \uparrow = \text{más dep.} \end{array}$$

* El coeficiente de contingencia de Pearson

$$\text{es } C = \sqrt{\frac{\chi^2}{n + \chi^2}}, \quad 0 \leq C \leq 1$$

* Si las modalidades del atributo A y B están ordenadas, es posible definir

$$r = \frac{\sum x_i y_i}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

(donde x_i es el rango ordenado de A_i)

$$\begin{aligned} &= \dots \\ &= 1 - \frac{6 \sum_{i=1}^n (x_i - y_i)^2}{n(n^2 - 1)} \end{aligned}$$

$$\text{using } \sum x_i = 1 + \dots + n = \frac{n(n+1)}{2}$$

* Es el rango de correlación para rangos de Spearman.

Tema 9 - Series temporales

9.3 Componentes:

Las fluctuaciones de una serie temporal y_t son el resultado de cuatro componentes básicos:

- (1) Tendencia, T : largo
- (2) Ciclo, C : medio
- (3) Estacional, E : corto
- (4) Residuo, R : no poseen un carácter periódico

↳ Aditiva $y_t = T_t + C_t + E_t + R_t$

↳ Multiplicativa $y_t = T_t C_t E_t R_t$

↳ $\ln y_t = \ln T_t + \ln C_t + \dots$

↳ Solamente simplificar a $y_t = T_t + E_t$.

9.4 Detención de componentes:

- 'A ojo'

tema 10 - Análisis de la tendencia:

10.1 - Métodos de la media móvil:

- Calculamos la media en intervalos de p valores:

$$\bar{Y}(1) = \frac{Y_1 + \dots + Y_p}{p}, \bar{Y}(2) = \frac{Y_2 + \dots + Y_{p+1}}{p}, \dots$$

Si $p = \text{periodo}$, \bar{Y} elimina la parte estacional.

¿ A qué punto temporal asignamos \bar{Y} ?

→ Asimétrica: en el punto final del intervalo,
i.e. $\bar{Y}_p = \frac{1}{p}(Y_1 + \dots + Y_p)$.

→ Centrada: en el medio del intervalo,

$$\text{i.e. } \bar{Y}_{\frac{p+1}{2}} = \frac{1}{p}(Y_1 + \dots + Y_p)$$

↑ en este caso quitás $\frac{p+1}{2}$ & N
así que tenemos que hacer $\bar{Y}_{\frac{p+1}{2}} = \frac{\bar{Y}_{\frac{p+1}{2}} + \bar{Y}_{\frac{p+3}{2}}}{2}$.

10.2 - Método de ajuste mínima-cuadrática

- * Ajustamos una ecuación matemática para encontrar la tendencia. Quizás tengamos que utilizar las medidas anuales.

(\hookrightarrow) T: las medidas de bondad de ajuste no predicen al cincuenta por ciento pues los datos con estacionalidad se alejarán mucho de la ecuación de tendencia.

Tema II - Análisis de estacionalidad

II.1 Método de la razón a la tendencia

- Bajo hipótesis multiplicativa.

$$IBNE_t := \frac{Y_t}{T_t} = E_t \times R_t$$

↑ índices brutos de variación estacional

$$IVE_t = \sum_{j=1}^n \frac{IBNE_j}{n}, \quad i=1,2,3,4 \text{ (trimestres)}$$

, n = número de años.

También podemos normalizar, $\hat{IVE}_t = \frac{IVE_t}{IVE}$.

El IVE_t approxima la estacionalidad.

II.2 Método de la diferencia a la tendencia

- Bajo hipótesis aditiva (lo mismo que II.1)

$$DBNE_t = Y_t - T_t = \tilde{E}_t + R_t$$

↑ diferencias brutas de var. estacional

$$DVE_i = \sum_{j=1}^n \frac{DBNE_j}{n}, \quad \tilde{DVE}_i = DVE_i - \overline{DVE}.$$

II.3 Desestacionalización

$$D_t = \frac{Y_t}{IVE_t} \quad \circ \quad D_t = Y_t - \tilde{DVE}_t$$

Tema 12 - Números Índices

- Los números índices facilitan una medida que permite la comparación de magnitudes en observaciones históricas.
- Si tenemos una única variable, el índice se construye tomando un valor base (y_0). Luego, $I_t = \frac{y_t}{y_0} \times 100$.

• Las tasas de variación son $\frac{y_t - y_{t-1}}{y_{t-1}} \times 100$.

- A veces tenemos varias variables, por lo que si queremos reunir todos estos índices necesitamos $I_t = \frac{\sum_{i=1}^n y_{it}/y_{i0} \times 100}{n} = \frac{\sum_{i=1}^n I_{it}}{n}$

A veces ponderamos los índices $\frac{\sum I_{it} w_i}{\sum w_i}$

- Ejemplo: Índices de los precios

Intentar ponderar las cantidades y precios de diferentes productos

$$P_L = \frac{\sum_i P_{it} q_{i0}}{\sum_i P_{i0} q_{i0}}, Q_L = \frac{\sum_i q_{it} P_{i0}}{\sum q_{i0} P_{i0}}$$

Índices de Paasche

$$P_P = \frac{\sum_i P_{it} q_{it}}{\sum P_{i0} q_{it}}, Q_P = \frac{\sum_i q_{it} P_{it}}{\sum q_{i0} P_{it}}$$

12.4 Operaciones con números índices

- Cambio de base: si queremos cambiar el año base para hacer comparaciones

t	I_{t0}	I_t/h	con años anteriores debemos multiplicar todo I_{t0} por
0	I_{t0}	—	
1	I_{10}	—	
:	:		
h	I_{h0}	I_{hw}	$k = I_{hw}/I_{h0} = 100/I_{h0}$
$h+1$	—	I_{h+1w}	e.g. $I_{t/h} = I_{t0} \cdot k, t=0, 1, \dots, h+1$
:	—	:	

- Deflación de series económicas: el análisis de la evolución temporal de magnitudes económicas expresadas en unidades monetarias se ve afectada por la subida de los precios.

precios corrientes } : $VNE = \sum_{i=1}^n P_{it} q_{it}$

precios constantes } : $VR_T = \sum_{i=1}^n P_{i0} q_{it}$.

El proceso $VNE \rightarrow VR_T$ se conoce como deflación, y basta con dividir por el índice deflactor $P_p = \sum_i P_{it} q_{it} / \sum_i P_{i0} q_{it}$

- Repercusión: a veces es interesante saber el efecto de un cambio específico sobre el índice complejo (ej: efecto de un D en la electricidad sobre el IPC).

Repercusión absoluta: $R_i = \frac{\Delta I_{iw_i}}{\sum w_i}$

o reactiva: $R_{ri} = \frac{R_i}{I_{t-1}} \times 100$.

Participación: $P_i = \frac{R_i}{\sum R_i} \times 100 = \frac{R_i}{I_t - I_{t-1}} \times 100$.