

CAPÍTULO 9

9.1 Estimador de Variable Indep. en RS

- En un modelo $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, si x_i está ~~correlacionada~~ con ϵ_i el estimador $\hat{\beta}_1$ estará sesgado. Decimos que se da la condición de endogeneidad cuando $\text{cov}(x_i, \epsilon_i) \neq 0$.
- Una solución es el uso de variable instrumentales. Queremos encontrar una variable z tal que:
 - * $\text{cov}(z, \epsilon) = 0$ ← condición de exogeneidad
 - * $\text{cov}(z, x) \neq 0$ ← condición de relevancia

Se crea un estimador MC2E, de mínimos cuadrados en dos etapas:

$$\begin{aligned} \textcircled{1} \quad x_i &= \pi_0 + \pi_1 z_i + u_i \rightsquigarrow \hat{x}_i \\ \textcircled{2} \quad y_i &= \beta_0 + \beta_1 \hat{x}_i + \epsilon_i \rightsquigarrow \hat{y}_i, \hat{\beta}_1, \hat{\beta}_0 \end{aligned}$$

• Entonces $\hat{\beta}_1^{\text{MC2E}} \xrightarrow{P} \beta_1$.

9.2 Modelo general de regresión con VI

Modelo:

$$Y_{(t)} = \underbrace{\beta_0 + \beta_1 X_{(t)} + \dots + \beta_r X_{(r)}}_{\text{variables exógenas}} + \underbrace{\beta_{(r+1)} Y_{(1)} + \dots + \beta_{(k+r)} Y_{(k)}}_{\text{variables endógenas}} + \varepsilon_{(t)}$$

$\varepsilon_{(j)} = \pi_{0j} + \pi_{1j} x_{it} + \dots + \pi_{rj} x_{rt} + \pi_{(r+1)j} z_{(1)i} + \dots + u_{ij}$

* Condición de orden: al menos k variables instrumentales ~~correlacionadas~~ con $Y_{(t)}$

* Condición de rango: La matriz

$$\begin{pmatrix} \pi_{(r+1)1} & \dots & \pi_{(r+m)1} \\ \vdots & & \vdots \\ \pi_{(r+1)k} & \dots & \pi_{(r+m)k} \end{pmatrix} \text{ debe tener rango } = k.$$

$$u = \pi_z z + \pi_x x + u$$

Tenemos dos condiciones sobre los instrumentos:

* Relevancia del instrumento: los vectores

$$(1, x_{1i}, \dots, x_{ri}, \hat{y}_{1i}, \dots, \hat{y}_{ki})$$
 no pueden ser colineales.

* Exogeneidad del inst: $\text{cov}(z_j, \varepsilon_i) = 0 \forall j$.

9.3 La regresión VI para resolver la endogenidad

• Problema: * Omisión de una variable explicativa da lugar a endogenidad. Si encontramos un instrumento para la variable omitted podemos solucionarlo.

* Problema de medición, i.e. medimos $x_i^* = x_i + w_i$. Da lugar a $\text{cov}[x_i, \varepsilon_i] \neq 0$. Solución: encontrar z_i ~~correlacionado~~ con x_i^* pero no con w_i .

Entonces $\text{cov}[z_i, \varepsilon_i] = 0$

* Simultaneidad (Y afecta a X también).

. Test de endogenidad: contraste de especificación de Hausman. Contrastamos los estimadores MC2E y MC2E. Si son muy diferentes concluimos que la ecuación es endógena.

9.4 Validez de los instrumentos

$$\cdot \hat{\beta}_1^{\text{MC2E}} = \beta_1 + \frac{P_Z \varepsilon \cdot \varepsilon}{P_Z X \cdot X} \quad \text{por lo que necesitamos}$$

que $\text{cov}(z, X)$ sea grande para que el resultado sea fiable. Llamamos a esto la relevancia del instrumento. La segunda condición es la exogeneidad del instrumento, i.e.

$$\text{cov}(z, \varepsilon) = 0. \text{ Si no, no hay convergencia } \hat{\beta}_1 \rightarrow \beta_1.$$

9.5 Expresión matricial

$$\cdot Y = X\beta + \varepsilon, \text{ estimamos } \hat{X} = P_Z X = z(z^T z)^{-1} z^T X.$$

Después miramos $\varphi = \hat{X}\beta + u$. Por lo tanto

$$\hat{\beta}^{\text{MC2E}} = (\hat{X}^T \hat{X})^{-1} \hat{X}^T Y$$

$$= \beta + (X^T P_Z X)^{-1} X^T P_Z \varepsilon$$

$$\Rightarrow \sqrt{n}(\hat{\beta}^{\text{MC2E}} - \beta) \xrightarrow{d} N(0, V^{\text{MC2E}}) \quad \text{complicado.}$$

CAPÍTULO 10

Datos fusionados: y_t , t aleatorio

Datos de panel: y_{it}

10.1 Datos fusionados de sección cruzada

- Realizamos encuestas de tamaño N en T diferentes momentos ($= NT$ puntos). Esto dificulta la suposición idd.

$$y_{it} = \alpha + x_{it}^\top \beta + \varepsilon_{it}, \quad x_{it} \in \mathbb{R}^{k \times 1}$$

10.2 Datos de panel

- Si intentamos controlar por efectos no observados que son constantes en el tiempo pero varían entre unidades podemos recurrir al método de efectos fijos:

$$y_{it} = \beta_i X_{it} + \alpha_i + \varepsilon_{it}$$

* Se puede estimar utilizando mco + variables binarias, ie. $\alpha_1 \mathbf{1}_{\{i=1\}} + \dots + \alpha_n \mathbf{1}_{\{i=n\}}$.

Otra manera de hacerlo es $\bar{Y}_i = \sum_{t=1}^T y_{it}$, y similar para \bar{X}_i , $\bar{\varepsilon}_i$ tal que

$$\bar{Y}_i = \beta_i \bar{X}_i + \alpha_i + \bar{\varepsilon}_i. \text{ Entonces,}$$

$y_{it} - \bar{Y}_i = \beta_i (X_{it} - \bar{X}_i) + (\varepsilon_{it} - \bar{\varepsilon}_i)$. Estimamos el mco, lo cual nos conduce al mismo estimador. Después, $\hat{\alpha}_i = \bar{Y}_i - \hat{\beta}_i \bar{X}_i$
se llama estimador intragrupos o "within".

* Método de diferencias:

$$\Delta y_i = y_{it} - y_{i0} = \beta_i \Delta X_i + \Delta \varepsilon_i \rightsquigarrow \text{encontrar } \beta_i$$

- ¿Qué pasa con el modelo $y_{it} = \beta_i X_{it} + \alpha_i + \mu_t + \varepsilon_{it}$? Podemos usar variables binarias $\mathbf{1}_{\{i=1\}}, \mathbf{1}_{\{t=1\}}$ otra vez. También podemos hacer

$$y_{it} - \bar{Y}_{i..} - \bar{Y}_{..t} + \bar{Y}_{...} = \beta_1 (X_{it} - \bar{X}_{i..} - \bar{X}_{..t} + \bar{X}_{...}) + \beta_2 (\dots) + \dots + (\varepsilon_{it} - \bar{\varepsilon}_{i..} - \bar{\varepsilon}_{..t} + \bar{\varepsilon}_{...})$$

$$\text{donde } \bar{Y}_{...} = \frac{1}{(nT)} \sum_i \sum_t y_{it}.$$

* Datos de panel con efecto aleatorio

Modelo $y_{it} = x_{it}^\top \beta + \alpha_i + \varepsilon_{it}$ pero ahora $\alpha_i \sim [\alpha, \sigma_\alpha^2]$, ie. no es constante. Asumimos que $E[\alpha_i | X_{i1}, \dots, X_{iT}] = 0$. Let $v_{it} = \alpha_i + \varepsilon_{it}$, entonces $\text{corr}(v_{it}, v_{is}) \neq 0$, hay autocorrelación por lo que los errores estándar no serán correctos en la estimación mco.

1. Ante la duda utilizar efectos fijos, ya que estos son también consistentes bajo las suposiciones de efectos aleatorios.

3
métodos
para
efectos
fijos.

Capítulo 6

Capítulo 11

11.1 Introducción

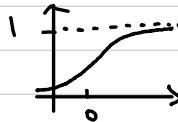
- Estudiamos modelos en los que la variable dependiente es cualitativa

11.2 Modelos lineales de probabilidad

- Si $y_i \in \{0, 1\}$ la regresión $y_i = \alpha + x_i^T \beta + \varepsilon_i$ da lugar al modelo lineal de prob. Notese que $P(Y_i=1) = E[Y_i] = \alpha + x_i^T \beta$
- Problemas: no tenemos necesariamente que $0 \leq \alpha + x_i^T \beta \leq 1$, $\text{var}(\varepsilon_i)$ depende de x_i por lo que no hay homocedasticidad, ε_i es binomial (no normal) ...

11.3 El modelo Logit

$$\cdot f(x) = \frac{1}{1+e^{-x}} \rightsquigarrow$$



Modelo: $y_i = \frac{1}{1+\exp\{-(\alpha + x_i^T \beta)\}}$ ← no lineal

- Si $P(Y_i=1) > 0.5$ entonces $\hat{y}_i = 1$. La proporción de aciertos nos da una manera de medir la bondad.
- Aquí $\partial Y_i / \partial \beta_j \neq \beta_j$ así que la interpretación de β_j es más complicada que en el antiguo modelo V2.

11.4 El modelo Probit

- La función de densidad acumulada de una normal, ϕ , también tiene la forma de S. El modelo es $P(Y_i=1) = \phi(\alpha + x_i^T \beta) = P(z \leq \alpha + x_i^T \beta)$, no lineal.

11.5 Estimación de modelos logit y probit

- Estos dos modelos se estiman con estimadores mvl (máxima verosimilitud). Si F es $f \circ \phi$ entonces la función de verosimilitud conjunta es

$$L = \prod_{i=1}^n F(x\beta)^{y_i} [1 - F(x\beta)]^{1-y_i} \quad y_i \in \{0, 1\}$$

Trabajamos con $\log(L)$. La condición $\frac{\partial \ln(L)}{\partial \beta} = 0$ nos deja estimar β , y la Hessiana $\frac{\partial^2 \ln(L)}{\partial \beta^2}$ estima asintóticamente $\text{var}(\hat{\beta})$.

Tema 13

13.1 Procesos estocásticos

- Sea $\{z_t : 1 \leq t \leq T\}$ un proceso estocástico con esperanza marginal $E[z_t] = \mu_t$, varianza marginal $\text{var}(z_t) = \sigma_t^2$. Además tenemos:
 - * Función de autocovarianza $\gamma(t, t+u) = \text{cov}(z_t, z_{t+u})$.
 - * Función de autocorrelación $\rho(t, t+u) = \frac{\text{cov}(z_t, z_{t+u})}{\sigma_t \sigma_{t+u}}$ con valores entre -1 y 1.
- Es estacionario en sentido estricto si las funciones de dist² son idénticas, i.e. $f(z_t) = f(z_s)$.
- Es estacionario en sentido débil si
 - * $\mu_t = \mu$, $\sigma_t^2 = \sigma^2$, $\gamma(t, t+u) = \gamma_u = \gamma_{-u}$
- Ej: Ruido blanco z_t con $E[z_t] = 0$, $\text{var}(z_t) = \sigma^2$ y $\text{cov}(z_t, z_{t+u}) = 0 \quad \forall u \neq 0$. Gaussiano si $z_t \sim N(0, \sigma^2)$.

13.2 Estimación de los momentos en procesos estacionarios

- media muestral: $\bar{z} = \frac{\sum_{t=1}^T z_t}{T}$. Notese que $E[\bar{z}] = \mu$. Llamamos al proceso ergódico si $\text{var}(\bar{z}) \rightarrow 0$ cuando $T \rightarrow \infty$. Estacionario \Leftrightarrow ergódico, ej: $z_t = z_1 + \epsilon_t$. Si el proceso es ergódico, $\bar{z} \xrightarrow{P} \mu$.
 - Notese que $\text{var}(\bar{z}) = \frac{1}{T} [\sigma^2 + 2 \sum_{t=1}^{T-1} (1 - \rho_t) \gamma_t]$. Si existe una dependencia débil en covarianza, i.e. $\gamma_u \rightarrow 0$ si $u \rightarrow \infty$, tendremos ergodicidad.
 - $\hat{\gamma}_u = \frac{1}{T} \sum_{t=u+1}^T (z_t - \bar{z})(z_{t-u} - \bar{z})$, $\hat{\rho}_u = \hat{\gamma}_u / \hat{\gamma}_0$.
- Para determinar si $\hat{\rho}_u$ es suficientemente distinto de 0 dibujamos un correlograma y lo comparamos con un proceso de ruido blanco ($E[\hat{\rho}_u] = 0$ y $\text{var}(\hat{\rho}_u) = 1/T$). De hecho aquí tendremos $\hat{\rho}_u \sim N(0, 1/T)$ e independiente. Podemos pues realizar un contraste de hipótesis nula $H_0: \rho_u = 0$, $| \hat{\rho}_u - 0 | / \sqrt{1/T} | > 1.96$.

13.3 Procesos integrados

- Muchas veces los procesos no son estacionarios en media y/o varianza. Hay dos transformaciones que pueden ayudar:
 - * Diferenciación: $\Delta X_t = X_t - X_{t-1}$, $\Delta^d = \Delta \circ \Delta \circ \dots \circ \Delta$.
 - * Dif. estacional: $X_t = X_t - X_{t-12}$ (por ejemplo).
- Un proceso $I(d, p)$ será integrado de orden d regular y orden 0 estacional.
- También está la transformación de Box-Cox. Si \bar{x}_i y s_{x_i} es la media y desviación típica hacemos un MCO $\ln s_{x_i} = c + (1-\lambda) \ln \bar{x}_i$. Calculamos λ y hacemos la transformación $y_t = x_t^\lambda - 1/\lambda$.

13.4 Procesos autoregresivos

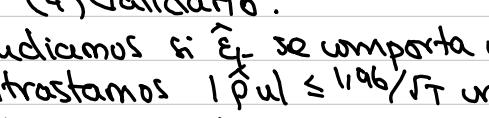
- Un proceso autoregresivo de orden p, AR(p), es $(*) z_t = \phi_0 + \phi_1 z_{t-1} + \dots + \phi_p z_{t-p} + \varepsilon_t$, donde ε_t es ruido blanco $\Leftrightarrow (1 - \phi_1 - \dots - \phi_p \phi_p) z_t = \varepsilon_t \Leftrightarrow AR(B) z_t = \varepsilon_t$.
- El proceso es estacionario si todas las raíces de $AR(B)$ tienen $| \cdot | > 1$.
- Notese que $z_t = AR(B)^{-1} \varepsilon_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$.

Para determinar el orden del proceso podemos mirar la función de autocorrelación parcial (FAP), que mide la influencia de z_{t-k} sobre z_t descontando la influencia indirecta que tiene a través de $z_{t-1}, \dots, z_{t-k+1}$. Llamamos al coef. ϕ_{kk} . ej:

$$\begin{aligned} z_t &= \phi_1 z_{t-1} \rightsquigarrow \phi_{11} = \phi_1 \\ z_t &= \phi_1 z_{t-1} + \phi_2 z_{t-2} \rightsquigarrow \phi_{22} = \phi_2 \end{aligned} \quad \begin{array}{l} \text{Estimación} \\ \text{MCO} \end{array}$$

También podemos estimar ϕ_{kk} con las ecuaciones de Yule-Walker: multiplicamos (*) por z_{t-u} y aplicamos $E[\cdot]$ $\rightsquigarrow \rho_u = \phi_1 \rho_{u-1} + \dots + \phi_p \rho_{u-p}$ $\Leftrightarrow (\phi_{11} \dots \phi_{uu}) = (\rho_1 \rho_2 \dots \rho_{u-1} \rho_u)^{-1} \left(\begin{array}{c} \rho_1 \\ \vdots \\ \rho_u \end{array} \right)$.

- La FAP sólo es significativa en procesos AR(p)
- significativa en procesos AR(p) cuando ϕ_{pp} ej.



13.5 Procesos de medias móviles

- Modelo $z_t = c + \varepsilon_t - \theta_1 z_{t-1} - \dots - \theta_q z_{t-q}$, $= MA(B) \varepsilon_t \Leftrightarrow \varepsilon_t = MA(B)^{-1} z_t$.
- Si las raíces son $| \cdot | > 1$, convergerá, por lo que escribimos $z_t = \sum_{j=1}^q \eta_j z_{t-j} + \varepsilon_t$, i.e. es un proceso AR(q). La FAP decrece geométricamente y la FAT es finita en los primeros q términos, i.e. la FAT y FAP se intercambian roles.

- Un proceso es invertible si se puede escribir como AR(q).

13.6 Procesos ARIMA

- Modelo $z_t = \sum_{j=1}^p \phi_j z_{t-j} - \sum_{i=0}^q \theta_i \varepsilon_{t-i}$ $\in ARIMA(p, q)$

$$\Leftrightarrow AR(B) z_t = MA(B) \varepsilon_t. \text{ Invertible si las raíces de MA son } | \cdot | > 1 \text{ y estacionario si lo mismo con las raíces de AR (si no comparten raíces). Entonces se puede expresar como AR(q) o MA(q).}$$

- Elegimos el modelo en un rango razonable para p y q, via la maximización de verosimilitud, que minimice la BIC o AIC.

13.7, 13.8 Procesos ARIMA

- w_t es un proceso ARIMA(p, d, q) si $\Delta^d w_t$ es ARMA(p, q), donde $\Delta w_t = w_t - w_{t-1}$.

- Los modelos SARIMA, o ARIMA estacionales, son aquellos con retardos estacionales s, 2s, 3s, ..., ej: SAR(2) es $z_t = \phi_1 z_{t-s} + \phi_2 z_{t-2s} + \varepsilon_t$.

$$Q(k) = T(T+2) \sum_{i=1}^k \frac{\hat{\rho}_i^2}{T-i} \times x_{n+k}^2 \text{ bajo } \chi^2 \text{ estadístico Q}$$

13.10 Predicción

- Si $\hat{z} = \{z_1, \dots, z_T, \varepsilon_1, \dots, \varepsilon_T, \phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q\}$ entonces predecimos $\hat{z}_{t+h} = E[z_{t+h} | \hat{z}_T]$.

$$\hat{z}_{t+1} = E[c + \phi_1 z_{t-1} + \varepsilon_{t+1} | \hat{z}_T] = c + \phi_1 z_t \text{ y el error es } \text{err}(\hat{z}_{t+1}) = z_{t+1} - \hat{z}_{t+1} = c + \phi_1 z_t + \varepsilon_{t+1} - c - \phi_1 z_t = \varepsilon_{t+1}.$$

En general $\hat{z}_{t+h} = c(1 + \phi_1 + \dots + \phi_{h-1}) + \phi_h z_t \rightarrow c / (1 - \phi_1)$, i.e. as h $\rightarrow \infty$ la predicción tiende a la media.

13.11 Modelos autoregresivos con predictores

- Modelo $y_t = \beta_0 + \sum_{i=1}^p \beta_i y_{t-i} + \sum_{j=1}^q \delta_j x_{t-j} + \varepsilon_t$.

↳ modelo autoregresivo de retardos distribuidos, ARIM(p, q).

Tema 16

• Tratamos efectos causales dinámicos, ej:

$$Y_t = f(X_t) + \epsilon_t \quad \text{donde } \epsilon_t = g(\epsilon_{t-1})$$

o $Y_t = f(X_t, X_{t-1}, \dots) + \epsilon_t$. modelos de retardos distribuidos (RD).

- Los autoregresivos RD, i.e. ARD, son tales que $Y_t = f(Y_{t-1}, X_t, X_{t-1}, \dots) + \epsilon_t$.
- En los modelos RD asumimos exogeneidad, i.e. $E[\epsilon_t | X_t, X_{t-1}, \dots] = 0$, para estimar los coeficientes MC consistentemente.

$$\hookrightarrow Y_t = \beta_0 + \beta_1 X_t + \dots + \beta_{k+1} X_{t-k} + \epsilon_t.$$

También asumimos que Y_t, X_t son estacionarios.

- Un modelo dinámico completo incluiría X_t , i.e. un vector de regresores en cada momento.
- Modelos ARD(P, q):

$$Y_t = \sum_{i=1}^q Y_i g_{t-i} + \sum_{i=0}^P \beta_i X_{t-i} + \epsilon_t$$

$$\Leftrightarrow C(B) Y_t = A(B) X_t + \eta_t$$

$$\hookrightarrow Y_t = \frac{A(B)}{C(B)} X_t + \eta_t$$

B = backward operator

Tema 17

17.1 Tendencias

- Existen tendencias deterministas (ej.: $y_t = \beta_0 + \beta_1 t + \varepsilon_t$) donde la media cambia por una función. Las tendencias estocásticas tienen una media constante pero se deben a sumas de variables aleatorias causadas por, por ejemplo, raíces unitarias:

* Paseo aleatorio: $y_t = y_{t-1} + \varepsilon_t$ (ie. $\phi_1 = 1$)

$$\Rightarrow y_t = y_0 + \sum_{i=0}^{t-1} \varepsilon_i.$$

La media es estacionaria ($EY_t = EY_0$) pero la varianza no ($\text{var } y_t = \sum \text{var } \varepsilon_i = t\sigma_\varepsilon^2$).

17.2 Regresiones espurias

- Si y_t, x_t son paseos aleatorios independientes y regresamos $y_t = \alpha + \beta_0 x_t + u_t$. Al hacer MCU, observamos que rechazamos $H_0: \beta_0 = 0$ un prob' cuando $t \rightarrow \infty$. ¿Por qué? Porque aunque H_0 es mala, lo también lo es y $\text{var}(y_t) \rightarrow \infty$ pero $\text{var}(\alpha + u_t) = \sigma_u^2 \ll \infty$.
- Por eso si regresamos consumo = $\beta_1 \text{PIB}_t + \alpha$ vemos que β es significativo: no hay relación causal pero al menos hay variación.
- Si $DW < R^2$ entonces hay riesgo de reg. espuria.

17.3 Contraste de raíces unitarias

- Para contrastar un AR(1) $y_t = \rho y_{t-1} + \varepsilon_t$ si queremos ver si hay raíz unitaria ($H_0: \rho = 1$) hacemos un contraste de Dickey-Fuller (DF), ie. $\hat{\rho} - 1 \rightarrow DF_i$ ($\begin{cases} i=0 & \text{si no hay deriva} \\ i=1 & \alpha \\ i=2 & \alpha + \beta \end{cases}$)
- Para $\Delta y_t = \delta y_{t-1} + \sum_{i=1}^2 \gamma_i \Delta y_{t-i} + \varepsilon_t$ hacemos un contraste aumentado de Dickey-Fuller (ADF).

17.4 Orientaciones en la modelación

- Intenta diferenciar cuando el proceso sea $I(i)$ para un seguir una serie estacionaria.

Tema 18

- Hay procesos (ej. activo bursátil) donde no hay homocovariancia. Los modelos ARCH (autoregresivo heterocedástico condicionado) son tales que los residuos estimados tengan una estructura AR, ie.

$$\hat{\varepsilon}_t^2 = \alpha_0 + \alpha_1 \hat{\varepsilon}_{t-1}^2 + \dots + \alpha_q \hat{\varepsilon}_{t-q}^2 + v_t \quad \begin{matrix} \leftarrow \text{ruido} \\ \text{blanco} \end{matrix}$$

- Una alternativa son los de perturbación multiplicativa:

$$\varepsilon_t = v_t \sqrt{\alpha_0 + \alpha_1 \varepsilon_{t-1}^2}. \text{ Entonces,}$$

$$\mathbb{E}[\varepsilon_t^2 | \varepsilon_{t-1}, \dots] = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2, \text{ ie. ARCH(1).}$$

- ARCH(q) son $\varepsilon_t = v_t \sqrt{\alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2}$

- Los modelos GARCH son una generalización, permitiendo que la varianza condicionada sea un proceso ARMA, ie: $\sigma_t^2 = \sqrt{h_t}$ donde $h_t = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{i=1}^p \beta_i h_{t-i}$.

Modelizacióñ

(1) Estimar $\{\hat{\varepsilon}_t^2\}$ usando un ARMA para estimar $\hat{\varepsilon}_t^2$.

(2) Dibujar autocorrelaciones muestrales de $\hat{\varepsilon}_t^2$ (ie. \hat{R}_{22}) para saber si GARCH es apropiado.

(?) Utilizar MCOs para estimar GARCH.

Tema 19

19.1 Introducción

- Modelo de vectores autoregresivos (VAR):

$$\begin{aligned} x_t &= \alpha_{10} + \alpha_{11} x_{t-1} + \dots + \alpha_{1p} x_{t-p} + \beta_{11} y_{t-1} + \dots + u_{1t} \\ y_t &= \alpha_{20} + \alpha_{21} x_{t-1} + \dots + \beta_{21} y_{t-1} + \dots + u_{2t} \end{aligned}$$

$$\Leftrightarrow \underline{w}_t = \underline{A}_0 + \underline{A}_1 \underline{w}_{t-1} + \dots + \underline{A}_p \underline{w}_{t-p} + \underline{u}_t$$

19.2 Estimación y orden del VAR

- Si asumimos errores homocedásticos y no autocorrelados, los estimadores MLE son consistentes y asintóticamente normales.
- selección entre $\text{VAR}(p)$ y $\text{VAR}(q)$: estimamos matrices de covarianzas $\hat{\Sigma}_p, \hat{\Sigma}_q$ y entonces $T[\ln(\det \hat{\Sigma}_p) - \ln(\det \hat{\Sigma}_q)] \sim \chi^2_{pq}$. También podemos comparar con AIC.

19.3 Diferentes formas del VAR

- La VAR estructural (SVAR) incluye los valores actuales, ie.

$$\begin{pmatrix} x_t \\ y_t \end{pmatrix} = \begin{pmatrix} 0 & Y_{12} \\ Y_{21} & 0 \end{pmatrix} \begin{pmatrix} x_{t-1} \\ y_{t-1} \end{pmatrix} + \begin{pmatrix} \alpha_{11} & \beta_{11} \\ \alpha_{21} & \beta_{21} \end{pmatrix} \begin{pmatrix} x_{t-1} \\ y_{t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}.$$

Se puede manipular para que sea un VAR, pero después no se puede retornar al modelo. Ver 18.707.

19.4 Predicción

$$\mathbb{E}[w_{t+1} | w_t, \dots, w_1] = \hat{w}_{t+1} = \underline{A}_0 + \underline{A}_1 w_t \quad q$$

$$\hat{w}_{t+1} = (\mathbf{I} + \underline{A}_1 + \dots + \underline{A}_p^{p-1}) \underline{A}_0 + \underline{A}_p w_t.$$

19.5 Causalidad de Granger

$$x_t = \alpha_{11} x_{t-1} + \dots + \beta_{11} y_{t-1} + \dots + u_{1t}$$

$$y_t = \alpha_{21} x_{t-1} + \dots + \beta_{21} y_{t-1} + \dots + u_{2t}$$

- Si los coef β_{ji} son significativos pero α_{ji} no, diremos que hay causalidad de Granger de y a x , and so on...

- Podemos expresar también los modelos VAR como vectores MA(q), ie:

$$\begin{pmatrix} x_t \\ y_t \end{pmatrix} = \sum_{i=1}^{\infty} \begin{pmatrix} \psi_{11}(i) & \psi_{12}(i) \\ \psi_{21}(i) & \psi_{22}(i) \end{pmatrix} \begin{pmatrix} u_{1(t-i)} \\ u_{2(t-i)} \end{pmatrix}. \quad \text{Se}$$

llaman funciones ($\psi(i)$) de respuesta al impulso (FRI).

Tema 20

20.1 Introducción

- En series univariadas $I(1)$ puede darse regresiones espurias, las cuales solucionamos diferenciando para obtener series estacionarias.
- En modelos VAR con la misma problemática podemos utilizar la cointegración. X_t e Y_t están cointegradas si ambas son $I(1)$ pero existe una combinación lineal estacionaria.

20.2 Cointegración

- X_t e Y_t están cointegradas de orden $d, b, d > b$ (y escribimos $CI(d,b)$) si ambas son $I(d)$ y existen β_1, β_2 tal que $\beta_1 Y_t + \beta_2 X_t$ es $I(d-b)$.

20.3 Contraste (Engle y Granger)

- (1) Utilizar test ADF para contrastar si ambas series son $I(1)$.
- (2) Estimamos $Y_t = \alpha + \beta X_t + \epsilon_t$ con MCO y conseguimos $\epsilon_t = \hat{\epsilon}_t$. Debe ser estacionaria al largo plazo si hay cointegración.
- (3) Contrastamos la estacionalidad de ϵ_t con un nuevo test ADF, ie. $\Delta \epsilon_t = \delta \epsilon_{t-1} + \sum \delta_i \Delta \epsilon_{t-i} + \eta_t$ y nos: $\delta = 0$.